

PLANEJAMENTO DO TCC 05/01

1 INTRODUÇÃO

A crescente disponibilidade de dados públicos e o avanço das técnicas de aprendizado de máquina têm possibilitado o desenvolvimento de sistemas preditivos capazes de auxiliar na análise de problemas socioeconômicos. Entre esses problemas, destaca-se a estimativa da renda individual, uma variável importante para estudos sobre desigualdade, mercado de trabalho, planejamento profissional e formulação de políticas públicas.

A previsão de renda, entretanto, é uma tarefa complexa. A renda de um trabalhador não depende apenas de uma característica isolada, como a escolaridade, mas de um conjunto de fatores relacionados à formação, idade, experiência, ocupação, localização geográfica, carga horária de trabalho, formalização do vínculo e outras condições socioeconômicas. Além disso, existem fatores não observáveis, como habilidades individuais, oportunidades, redes de contato e condições específicas do mercado de trabalho, que também influenciam a renda, mas nem sempre estão disponíveis nas bases de dados.

Modelos econométricos tradicionais, como a equação de Mincer, são amplamente utilizados para analisar a relação entre escolaridade, experiência e rendimento. Esses modelos possuem como principal vantagem a interpretabilidade, pois sua estrutura permite compreender diretamente o papel das variáveis por meio dos coeficientes estimados. No entanto, por serem baseados em relações lineares, podem apresentar limitações para capturar padrões mais complexos, interações entre variáveis e efeitos não lineares presentes em dados socioeconômicos reais.

Por outro lado, técnicas modernas de Machine Learning, especialmente algoritmos baseados em árvores e Gradient Boosting, como XGBoost, LightGBM e CatBoost, apresentam bom desempenho em problemas de previsão com dados tabulares. Esses modelos conseguem identificar relações complexas entre variáveis e melhorar a capacidade preditiva em comparação a modelos lineares

tradicionais. Entretanto, essa maior flexibilidade também traz um desafio: modelos mais complexos tendem a ser menos interpretáveis em sua estrutura interna.

Dessa forma, é importante distinguir dois conceitos relacionados, mas diferentes: interpretabilidade e explicabilidade. Um modelo interpretável é aquele cuja estrutura pode ser compreendida de forma direta, como ocorre em uma regressão linear. Já a explicabilidade está relacionada à capacidade de explicar como um modelo chegou a determinada previsão, mesmo quando sua estrutura interna é complexa. Nesse contexto, técnicas como análise de importância de variáveis e métodos baseados em SHAP podem auxiliar na compreensão dos fatores que mais influenciam as previsões de modelos de Machine Learning.

Diante desse cenário, este trabalho propõe o desenvolvimento de um sistema completo de previsão da renda mensal do trabalho principal, utilizando microdados da PNAD Contínua. O projeto busca não apenas construir um modelo preditivo, mas também comparar diferentes abordagens de modelagem, analisando o equilíbrio entre desempenho, interpretabilidade, explicabilidade e aplicabilidade prática no contexto de Sistemas de Informação.

O projeto integra:

- Pipeline de processamento e engenharia de atributos;
- Avaliação comparativa entre modelos lineares e algoritmos de aprendizado de máquina;
- Implementação de um modelo híbrido combinando estrutura econométrica e aprendizado supervisionado;
- Desenvolvimento de uma arquitetura de software composta por backend em Python e interface web em React para disponibilização das previsões.

O objetivo principal é analisar empiricamente se modelos baseados em aprendizado de máquina apresentam desempenho superior a abordagens estruturais tradicionais na tarefa de previsão de renda, e se uma estratégia híbrida pode oferecer um equilíbrio entre capacidade preditiva e fundamentação interpretável.

Além disso, o trabalho considera a importância da explicabilidade dos modelos, uma vez que, em problemas socioeconômicos, não basta apenas prever um valor: também é necessário compreender, ainda que parcialmente, quais variáveis

contribuem para essa previsão e quais limitações devem ser consideradas na interpretação dos resultados.

Como contribuição, o trabalho apresenta:

- Um pipeline reproduzível de modelagem aplicado a microdados públicos;
- Comparação experimental padronizada entre diferentes algoritmos;
- Proposição e avaliação de um modelo híbrido estruturado;
- Discussão sobre desempenho, interpretabilidade e explicabilidade dos modelos;
- Implementação prática de um sistema preditivo funcional.

2 REFERENCIAL TEÓRICO

2.1 Teoria do Capital Humano e Equação de Mincer

A renda do trabalho é tradicionalmente analisada a partir da Teoria do Capital Humano, segundo a qual investimentos em educação, qualificação e experiência profissional tendem a aumentar a produtividade individual e, consequentemente, os salários. Nessa perspectiva, indivíduos com maior escolaridade ou maior experiência no mercado de trabalho tendem a apresentar melhores oportunidades de emprego e maiores rendimentos.

Dentro dessa abordagem, a equação de Mincer tornou-se um dos modelos econométricos mais utilizados para estimar os retornos da educação sobre a renda. A formulação clássica desse modelo relaciona o logaritmo da renda com os anos de estudo e a experiência do trabalhador, incluindo frequentemente um termo quadrático para representar retornos decrescentes da experiência ao longo do tempo.

A equação pode ser representada da seguinte forma:

$$\log(y) = \beta_0 + \beta_1 \cdot \text{escolaridade} + \beta_2 \cdot \text{experiencia} + \beta_3 \cdot \text{experiencia}^2 + \varepsilon$$

Nessa formulação, y representa a renda, β_0 é o intercepto do modelo, β_1 , β_2 e β_3 representam os coeficientes associados às variáveis explicativas, e ε representa o termo de erro.

Esse tipo de modelo apresenta vantagens importantes, como:

- Interpretabilidade direta dos coeficientes;
- Fundamentação teórica consolidada;
- Simplicidade computacional;
- Facilidade de comparação com estudos anteriores.

A principal vantagem da equação de Mincer é sua interpretabilidade. Como se trata de um modelo linear, é possível analisar diretamente o efeito estimado de cada variável sobre a renda. Por exemplo, o coeficiente associado à escolaridade pode ser interpretado como uma aproximação do retorno percentual de um ano adicional de estudo sobre o rendimento do trabalhador.

Entretanto, apesar de sua relevância teórica, esse tipo de modelo pode apresentar limitações quando aplicado a fenômenos socioeconômicos complexos. A renda não depende apenas da escolaridade e da experiência de forma linear, mas também de interações entre múltiplas variáveis, como região, ocupação, formalização do vínculo, idade, setor de atividade e características do domicílio. Por isso, modelos puramente lineares podem não capturar adequadamente relações não lineares e padrões mais complexos presentes nos dados.

2.2 Modelos de Regressão e Regularização

Em problemas com múltiplas variáveis explicativas, modelos lineares tradicionais podem sofrer com problemas como multicolinearidade, instabilidade dos coeficientes e sobreajuste. Para lidar com essas limitações, técnicas de regularização, como Ridge, Lasso e ElasticNet, são frequentemente utilizadas.

A regularização consiste em adicionar uma penalização à função de perda do modelo, reduzindo a complexidade da regressão e tornando os coeficientes mais estáveis. O modelo Ridge utiliza penalização L2, que reduz a magnitude dos

coeficientes, enquanto o Lasso utiliza penalização L1, que pode fazer com que alguns coeficientes se tornem zero, funcionando também como uma técnica de seleção de variáveis.

O ElasticNet combina as penalizações L1 e L2, permitindo simultaneamente controle de multicolinearidade e seleção de variáveis. Essa característica torna o método útil em bases de dados com muitas variáveis ou com variáveis altamente correlacionadas.

Apesar de serem mais robustos do que a regressão linear simples, esses modelos ainda mantêm uma estrutura essencialmente linear. Assim, eles continuam apresentando limitações para capturar relações não lineares complexas e interações automáticas entre variáveis. Por esse motivo, em problemas preditivos com dados tabulares, modelos de aprendizado de máquina baseados em árvores têm sido amplamente utilizados como alternativa.

2.3 Machine Learning Aplicado a Dados Tabulares

Com o avanço da capacidade computacional e a maior disponibilidade de dados, técnicas de Machine Learning passaram a ser amplamente aplicadas à previsão de variáveis econômicas e sociais. Diferentemente dos modelos econométricos tradicionais, que frequentemente partem de uma estrutura funcional previamente definida, os modelos de aprendizado de máquina buscam identificar padrões nos dados com foco principal na capacidade preditiva.

No contexto de dados tabulares, algoritmos baseados em árvores de decisão e em métodos de ensemble têm apresentado bons resultados. Entre os métodos mais utilizados estão os algoritmos baseados em Gradient Boosting, como:

- XGBoost;
- LightGBM;
- CatBoost.

Esses algoritmos constroem conjuntos de árvores de decisão de forma sequencial, em que cada nova árvore busca corrigir os erros cometidos pelas

anteriores. O processo ocorre por meio da minimização de uma função de perda, utilizando técnicas de otimização baseadas em gradiente.

A principal vantagem desses modelos está na capacidade de:

- Capturar relações não lineares;
- Modelar interações complexas entre variáveis;
- Lidar bem com dados tabulares;
- Apresentar alto desempenho preditivo;
- Tratar variáveis categóricas de forma eficiente, especialmente no caso do CatBoost.

O CatBoost, em particular, apresenta vantagens importantes para problemas que envolvem muitas variáveis categóricas, pois possui mecanismos próprios para lidar com esse tipo de dado sem exigir, necessariamente, a aplicação manual de técnicas como one-hot encoding. Isso o torna adequado para bases socioeconômicas, nas quais há variáveis como região, ocupação, setor de atividade, escolaridade e situação de trabalho.

No entanto, embora esses modelos apresentem maior flexibilidade e melhor desempenho em muitos problemas preditivos, eles possuem menor interpretabilidade estrutural quando comparados a modelos lineares. Em uma regressão, os coeficientes podem ser analisados diretamente. Já em modelos como CatBoost ou XGBoost, a previsão resulta da combinação de várias árvores, o que torna mais difícil compreender diretamente como cada variável influencia o resultado final.

2.4 Trade-off entre Interpretabilidade e Performance

Um dos principais desafios no uso de Machine Learning em problemas socioeconômicos é o equilíbrio entre desempenho preditivo e compreensão do modelo. Modelos lineares, como a regressão baseada na equação de Mincer, apresentam menor complexidade e maior interpretabilidade, mas podem ter desempenho limitado quando os dados apresentam relações não lineares.

Por outro lado, modelos baseados em Machine Learning tendem a apresentar maior capacidade preditiva, pois conseguem capturar padrões mais complexos. Entretanto, essa flexibilidade costuma reduzir a transparência do modelo, dificultando a compreensão direta da relação entre as variáveis de entrada e a previsão gerada.

No contexto de Sistemas de Informação, essa discussão é especialmente relevante, pois o desenvolvimento de um sistema preditivo não deve considerar apenas a acurácia do modelo. Também é necessário avaliar aspectos como:

- Precisão preditiva;
- Transparência do modelo;
- Explicabilidade dos resultados;
- Complexidade computacional;
- Manutenibilidade do sistema;
- Facilidade de integração com a aplicação.

Em problemas envolvendo renda, essa discussão se torna ainda mais importante, pois o resultado produzido pelo modelo pode ser interpretado por usuários como uma estimativa sobre sua condição socioeconômica. Dessa forma, é necessário deixar claro que a previsão gerada pelo sistema representa uma estimativa estatística baseada nos dados disponíveis, e não uma determinação exata ou definitiva da renda de um indivíduo.

Além disso, deve-se evitar interpretar automaticamente os resultados do modelo como relações causais. Um modelo preditivo pode indicar que determinada variável contribui para melhorar a previsão, mas isso não significa, necessariamente, que essa variável causa diretamente o aumento ou a redução da renda. Essa distinção é essencial para uma análise metodologicamente correta.

2.5 Interpretabilidade e Explicabilidade em Modelos de Machine Learning

Embora os termos interpretabilidade e explicabilidade sejam frequentemente utilizados de forma semelhante, eles não possuem exatamente o mesmo

significado. Essa distinção é importante para compreender os limites e as possibilidades dos modelos utilizados neste trabalho.

A interpretabilidade está relacionada à facilidade de compreender a estrutura interna de um modelo. Modelos lineares, por exemplo, são considerados interpretáveis porque seus coeficientes indicam diretamente a direção e a intensidade estimada da relação entre cada variável explicativa e a variável alvo. Assim, é possível observar, de forma relativamente simples, como escolaridade, experiência ou idade se relacionam com a renda prevista.

A explicabilidade, por sua vez, refere-se à capacidade de explicar o comportamento de um modelo, especialmente quando ele possui uma estrutura complexa. Um modelo pode não ser interpretável em sua estrutura interna, mas ainda assim pode ser explicado por meio de técnicas auxiliares. Esse é o caso de modelos como XGBoost, LightGBM e CatBoost, que são compostos por múltiplas árvores de decisão e não permitem uma interpretação direta tão simples quanto uma regressão linear.

Nesse contexto, métodos de explicabilidade, como análise de importância de variáveis e SHAP values, são utilizados para compreender quais atributos mais contribuem para as previsões do modelo. O SHAP, em especial, busca atribuir a cada variável uma contribuição para determinada previsão, permitindo analisar o impacto relativo de fatores como escolaridade, idade, ocupação, região, horas trabalhadas e formalização do vínculo.

A literatura recente tem utilizado técnicas de explicabilidade em modelos de Machine Learning aplicados a problemas socioeconômicos. Herrera et al. (2023), por exemplo, aplicam modelos de aprendizado de máquina e SHAP values para analisar a relação entre tecnologias da informação, características socioeconômicas e distribuição de renda no Brasil. Esse tipo de abordagem demonstra que modelos complexos podem ser utilizados não apenas para previsão, mas também como apoio à análise dos fatores associados à renda.

No presente trabalho, essa distinção é relevante porque os modelos comparados possuem naturezas diferentes. A regressão baseada na equação de Mincer apresenta maior interpretabilidade estrutural, enquanto o CatBoost apresenta maior capacidade preditiva, mas menor interpretabilidade direta. Assim, a análise dos resultados deve considerar tanto o desempenho dos modelos quanto a

possibilidade de explicar, ainda que parcialmente, os fatores que influenciam suas previsões.

É importante destacar, contudo, que explicabilidade não equivale a causalidade. Métodos como SHAP e importância de variáveis ajudam a entender como o modelo utiliza as informações disponíveis para realizar previsões, mas não provam que uma variável causa diretamente determinado resultado de renda. Portanto, neste trabalho, as análises de importância e explicação dos modelos devem ser entendidas como apoio à interpretação preditiva, e não como inferência causal.

2.6 Modelos Híbridos

Uma abordagem intermediária entre modelos econométricos tradicionais e modelos de Machine Learning consiste na construção de modelos híbridos. Nessa estratégia, um modelo estrutural é utilizado para capturar a parte teoricamente fundamentada do problema, enquanto um algoritmo de aprendizado de máquina é aplicado para modelar a parcela não explicada pelo modelo inicial.

No caso da previsão de renda, o modelo estrutural pode ser representado por uma regressão baseada na equação de Mincer, responsável por estimar a relação entre renda, escolaridade e experiência. Em seguida, um modelo de Machine Learning, como o CatBoost, pode ser treinado sobre os resíduos da regressão, ou seja, sobre a diferença entre os valores reais e os valores previstos pelo modelo estrutural.

Formalmente, essa abordagem pode ser representada da seguinte forma:

$$\log(y) = f_{\text{estrutural}}(X) + f_{\text{ML}}(X)$$

Nessa formulação, $f_{\text{estrutural}}(X)$ representa o componente estimado pelo modelo econométrico, enquanto $f_{\text{ML}}(X)$ representa o componente aprendido pelo modelo de Machine Learning a partir dos padrões restantes nos dados.

Essa estratégia busca combinar:

- A interpretabilidade do modelo estrutural;
- A fundamentação teórica da equação de Mincer;
- A flexibilidade não linear do Machine Learning;
- A capacidade de capturar padrões que não foram explicados pela regressão inicial.

A principal vantagem do modelo híbrido é permitir uma ponte entre a abordagem econométrica e a abordagem preditiva. Enquanto o modelo estrutural contribui com uma base teórica e interpretável, o modelo de Machine Learning complementa a previsão ao capturar interações e efeitos não lineares presentes nos resíduos.

No presente trabalho, essa abordagem foi implementada combinando uma regressão linear baseada na equação de Mincer com um modelo CatBoost aplicado aos resíduos do modelo estrutural. Dessa forma, buscou-se avaliar se a combinação entre uma estrutura econométrica interpretável e um modelo preditivo flexível poderia oferecer melhor equilíbrio entre desempenho, interpretabilidade e explicabilidade.

3 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos adotados para a construção, treinamento, avaliação e análise dos modelos preditivos desenvolvidos neste trabalho. São apresentados a base de dados utilizada, o processo de limpeza e preparação dos dados, a engenharia de atributos, a estratégia de divisão entre treino, validação e teste, as transformações aplicadas à variável alvo, os modelos avaliados, o protocolo experimental e as métricas utilizadas.

Além da avaliação preditiva, a metodologia também considera a diferença entre interpretabilidade e explicabilidade dos modelos. Essa distinção é importante porque o trabalho compara modelos de naturezas diferentes: modelos lineares, que possuem maior interpretabilidade estrutural, e modelos de Machine Learning, que podem apresentar melhor desempenho preditivo, mas exigem técnicas auxiliares para explicar seus resultados.

Dessa forma, a metodologia adotada busca avaliar não apenas qual modelo apresenta menor erro, mas também como cada abordagem se comporta em termos de

estabilidade, reprodutibilidade, complexidade e capacidade de apoiar a compreensão dos fatores associados à previsão da renda.

3.1 Base de Dados

A base utilizada neste trabalho é composta por microdados da Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua), disponibilizada pelo Instituto Brasileiro de Geografia e Estatística (IBGE). A PNAD Contínua fornece informações socioeconômicas detalhadas sobre a população brasileira, incluindo características demográficas, educacionais, ocupacionais e territoriais.

A escolha dessa base se justifica por sua relevância para estudos sobre mercado de trabalho, renda e desigualdade no Brasil. Por se tratar de uma pesquisa nacional, a PNAD Contínua permite analisar indivíduos de diferentes regiões, níveis de escolaridade, ocupações e condições socioeconômicas.

A variável alvo definida para o problema de previsão foi:

`renda_mensal_ocupacao_principal_deflacionado`

Essa variável representa a renda mensal do trabalho principal, ajustada por fatores de deflação para padronização temporal. A utilização da renda deflacionada é importante para reduzir distorções provocadas por variações de preços ao longo do tempo, permitindo maior comparabilidade entre observações.

Após o processo de limpeza, seleção e transformação das variáveis relevantes, o dataset consolidado, denominado versão v3, apresenta:

- 24 colunas;
- Variáveis demográficas, educacionais e ocupacionais;
- Conjuntos de treino, validação e teste previamente definidos;
- Variável alvo padronizada para o problema de previsão.

O conjunto de teste utilizado na avaliação final possui 25.801 observações e foi mantido fixo durante os experimentos. Essa decisão metodológica teve como

objetivo garantir comparabilidade entre os modelos avaliados, evitando que diferenças nos resultados fossem causadas por alterações na amostra de teste.

É importante destacar que, apesar da riqueza da PNAD Contínua, a renda individual também é influenciada por fatores não observáveis na base, como habilidades pessoais, qualidade da formação, redes de contato, reputação profissional, oportunidades locais e características específicas das empresas. Por esse motivo, as previsões realizadas devem ser interpretadas como estimativas estatísticas, e não como valores determinísticos ou exatos.

3.2 Engenharia de Atributos

A etapa de engenharia de atributos teve como objetivo transformar variáveis brutas da PNAD Contínua em atributos mais adequados para a modelagem preditiva. Essa etapa é essencial porque a qualidade das variáveis utilizadas influencia diretamente o desempenho dos modelos, especialmente em problemas socioeconômicos com relações complexas entre os fatores explicativos.

Foram utilizadas variáveis relacionadas a:

- Anos de estudo;
- Último grau frequentado;
- Indicadores de alfabetização;
- Idade;
- Idade ao quadrado;
- Experiência aproximada no mercado de trabalho;
- Horas trabalhadas por semana;
- Características ocupacionais;
- Região geográfica;
- Indicadores urbanos e metropolitanos;
- Indicador de carteira assinada.

A inclusão da idade ao quadrado e da experiência aproximada teve como objetivo capturar possíveis efeitos não lineares. Em estudos sobre renda, é comum que a experiência apresente retornos crescentes em determinados períodos da vida profissional, mas que esses retornos diminuam em idades mais avançadas. Por

isso, variáveis quadráticas ajudam a representar melhor esse tipo de comportamento.

Além das variáveis principais, foram criadas variáveis de interação, tais como:

- idade × anos_estudo;
- anos_estudo × horas_trabalhadas;
- anos_estudo × carteiraassinada;
- idade × horas_trabalhadas.

Essas interações foram incluídas para permitir que modelos lineares capturassem parcialmente relações combinadas entre variáveis. Por exemplo, o efeito da escolaridade sobre a renda pode variar conforme a quantidade de horas trabalhadas, a idade ou a formalização do vínculo de trabalho.

Nos modelos baseados em árvores, como CatBoost e XGBoost, parte dessas interações pode ser capturada automaticamente durante o treinamento. Mesmo assim, a criação explícita de algumas variáveis de interação permite maior controle metodológico e melhora a comparação com modelos lineares.

A engenharia de atributos também contribui para a explicabilidade do trabalho, pois permite relacionar as variáveis utilizadas pelo modelo com conceitos socioeconômicos conhecidos, como escolaridade, experiência, formalização, ocupação e região.

3.3 Divisão dos Dados

Os dados foram divididos em três subconjuntos principais:

- Treino;
- Validação;
- Teste.

O conjunto de treino foi utilizado para ajustar os modelos. O conjunto de validação foi utilizado para apoiar a escolha de parâmetros, verificar

desempenho intermediário e acompanhar possíveis problemas de sobreajuste. O conjunto de teste foi reservado para a avaliação final dos modelos.

A separação foi realizada previamente no pipeline de processamento da versão v3, garantindo:

- Redução do risco de vazamento de dados;
- Comparabilidade entre modelos;
- Reprodutibilidade dos experimentos;
- Avaliação final em dados não utilizados no treinamento.

A ausência de vazamento de dados é um ponto metodológico fundamental em projetos de Machine Learning. O vazamento ocorre quando informações do conjunto de teste ou da variável alvo são utilizadas indevidamente durante o treinamento, gerando resultados artificialmente altos e não generalizáveis.

Por esse motivo, o conjunto de teste foi mantido fixo durante toda a fase de comparação final. Assim, todos os modelos foram avaliados sobre a mesma base, assegurando uma comparação justa entre as diferentes abordagens.

3.4 Transformação Logarítmica da Variável Alvo

A distribuição de renda costuma apresentar forte assimetria, pois há grande concentração de indivíduos em faixas de renda mais baixas e uma quantidade menor de indivíduos com rendas muito elevadas. Essa característica pode dificultar o treinamento dos modelos, principalmente dos modelos lineares.

Para lidar com esse problema, foi aplicada transformação logarítmica à variável alvo durante o treinamento:

$$y_{\log} = \log(y)$$

Essa transformação apresenta as seguintes vantagens:

- Redução da assimetria da distribuição da renda;
- Estabilização da variância;

- Redução do impacto de valores extremos;
- Melhor adequação dos modelos lineares;
- Melhoria na convergência durante o treinamento;
- Interpretação mais adequada de erros proporcionais.

Os modelos foram treinados utilizando o logaritmo da renda. Posteriormente, as previsões foram reconvertidas para a escala original, em reais, permitindo interpretação prática dos resultados.

Essa decisão metodológica é relevante porque o erro em renda tende a ser proporcional. Por exemplo, errar R\$ 300,00 para uma pessoa com renda de R\$ 1.200,00 tem impacto relativo diferente de errar R\$ 300,00 para uma pessoa com renda de R\$ 10.000,00. A escala logarítmica ajuda a reduzir esse desequilíbrio durante o aprendizado.

3.5 Smearing Correction

A simples aplicação da exponenciação sobre previsões feitas em escala logarítmica pode introduzir viés na reconversão para a escala original da renda. Isso ocorre porque a esperança da exponencial do erro não é necessariamente igual a 1:

$$E[\exp(\varepsilon)] \neq 1 \quad E[\exp(\varepsilon)] \neq 1$$

Para corrigir esse viés, foi utilizado o fator de smearing. Esse fator é calculado a partir dos resíduos do modelo no conjunto de treino e permite ajustar a previsão após a transformação inversa do logaritmo.

O fator de smearing pode ser representado como:

$$SF = \frac{1}{n} \sum_{i=1}^n \exp(\hat{\varepsilon}_i^2)$$

em que $\hat{\varepsilon}_i$ representa os resíduos estimados do modelo no conjunto de treino.

A previsão final na escala original foi calculada como:

$$\hat{y} = \exp(\hat{y}_{\log}) \cdot SF$$

Esse procedimento reduz o viés gerado pela transformação logarítmica e torna as estimativas em escala monetária mais adequadas. Dessa forma, a previsão final apresentada pelo sistema corresponde a um valor estimado de renda mensal na escala original, ajustado pelo fator de correção.

3.6 Modelos Avaliados

Foram implementados e comparados diferentes modelos com o objetivo de avaliar o desempenho de abordagens lineares, modelos de aprendizado de máquina e uma estratégia híbrida.

Os modelos avaliados foram:

- Regressão Linear com regularização, utilizando ElasticNet;
- HistGradientBoosting;
- XGBoost;
- CatBoost;
- Modelo Híbrido, combinando Regressão Estrutural e CatBoost aplicado aos resíduos.

A Regressão Linear com regularização foi utilizada como uma abordagem mais simples e interpretável, servindo como base comparativa. O ElasticNet foi escolhido por combinar penalizações L1 e L2, permitindo maior estabilidade dos coeficientes e controle de multicolinearidade.

Os modelos baseados em Gradient Boosting foram utilizados por sua capacidade de capturar relações não lineares e interações complexas entre variáveis. Entre eles, o CatBoost recebeu destaque por sua capacidade de lidar com variáveis categóricas, característica importante em bases socioeconômicas como a PNAD Contínua.

O modelo híbrido foi estruturado em duas etapas:

1. Ajuste de um modelo linear baseado na equação de Mincer para estimar o componente estrutural da renda;

2. Treinamento de um modelo CatBoost sobre os resíduos do modelo estrutural;
3. Combinação das duas previsões para obtenção da estimativa final.

A lógica do modelo híbrido consiste em utilizar a regressão para capturar a parte mais interpretável e teoricamente fundamentada da renda, enquanto o CatBoost busca aprender os padrões restantes não explicados pela estrutura linear inicial.

Dessa forma, o modelo híbrido foi avaliado como uma alternativa intermediária entre interpretabilidade e desempenho preditivo.

3.7 Protocolo de Avaliação

Para garantir comparabilidade entre os modelos, foi adotado um protocolo experimental padronizado. Todos os modelos foram avaliados seguindo as mesmas condições de teste e utilizando a mesma estrutura de dados.

A avaliação considerou:

- Utilização do mesmo conjunto de teste da versão v3;
- Aplicação consistente da transformação logarítmica;
- Uso de smearing correction quando aplicável;
- Respeito à ordem e estrutura original das variáveis utilizadas no treinamento;
- Verificação explícita das features esperadas por cada modelo;
- Avaliação no espaço logarítmico e na escala original da renda.

Os modelos foram carregados e avaliados com verificação explícita das variáveis esperadas, evitando incompatibilidades estruturais entre versões do pipeline. Essa verificação é importante porque diferenças na ordem, nome ou tipo das colunas podem gerar previsões incorretas ou resultados não comparáveis.

Além da avaliação em conjunto de teste, foi utilizada validação cruzada em 5 folds no conjunto de treino. Essa etapa teve como objetivo avaliar a

estabilidade dos modelos e verificar se os resultados obtidos não dependiam excessivamente de uma única divisão dos dados.

A validação cruzada permitiu calcular a média e o desvio padrão das métricas de desempenho, fornecendo uma visão mais robusta sobre a capacidade de generalização dos modelos.

3.8 Métricas Utilizadas

Foram utilizadas métricas tanto no espaço logarítmico quanto na escala original da renda. Essa escolha permite avaliar o desempenho dos modelos sob duas perspectivas complementares: a escala usada no treinamento e a escala monetária, que é mais próxima da interpretação prática do problema.

No espaço logarítmico, foram utilizadas as seguintes métricas:

- Coeficiente de Determinação, representado por R^2 log;
- Root Mean Squared Error, representado por RMSE log;
- Mean Absolute Error, representado por MAE log.

Na escala original da renda, foram utilizadas:

- Coeficiente de Determinação, representado por R^2 ;
- Root Mean Squared Error, representado por RMSE;
- Mean Absolute Error, representado por MAE.

O R^2 indica a proporção da variabilidade da variável alvo explicada pelo modelo. O RMSE mede a raiz do erro quadrático médio, penalizando erros maiores de forma mais intensa. O MAE mede o erro absoluto médio, fornecendo uma interpretação mais direta do erro médio da previsão.

A avaliação em ambas as escalas permite:

- Analisar o desempenho no espaço de aprendizado;
- Avaliar o impacto prático da previsão em escala monetária;
- Comparar modelos de forma mais completa;
- Identificar diferenças entre desempenho estatístico e utilidade prática.

É importante destacar que, em problemas de previsão de renda, erros elevados podem ocorrer devido à alta variabilidade da variável alvo e à existência de fatores não observáveis nos dados. Assim, as métricas devem ser analisadas considerando a complexidade do fenômeno estudado.

3.9 Análise de Interpretabilidade e Explicabilidade

Além das métricas de desempenho, a metodologia também considerou aspectos relacionados à interpretabilidade e à explicabilidade dos modelos.

A interpretabilidade foi observada principalmente nos modelos lineares, em especial na regressão baseada na equação de Mincer. Nesse tipo de modelo, os coeficientes estimados permitem compreender diretamente a relação entre as variáveis explicativas e a renda prevista.

Já nos modelos de Machine Learning, como CatBoost e XGBoost, a estrutura interna é mais complexa. Por isso, esses modelos apresentam menor interpretabilidade direta, embora possam ser analisados por meio de técnicas auxiliares de explicabilidade.

Neste trabalho, a explicabilidade foi considerada por meio da análise da relevância das variáveis e da discussão sobre os fatores que mais contribuem para as previsões. Essa análise permite compreender, de forma aproximada, quais atributos possuem maior influência no comportamento do modelo, como escolaridade, idade, horas trabalhadas, ocupação, região e formalização do vínculo.

Também foi considerada a literatura recente que utiliza métodos como SHAP values para explicar modelos de Machine Learning aplicados a problemas socioeconômicos. Embora o foco principal deste trabalho esteja no desenvolvimento do sistema preditivo e na comparação de modelos, a discussão sobre explicabilidade foi incorporada como elemento metodológico importante para evitar que os modelos sejam analisados apenas como “caixas-pretas”.

É importante reforçar que a análise de explicabilidade não deve ser confundida com inferência causal. A importância de uma variável para o modelo indica que ela contribui para melhorar a previsão, mas não prova que essa variável causa diretamente o aumento ou a redução da renda. Portanto, as interpretações realizadas neste trabalho devem ser entendidas como análises preditivas e associativas, e não como conclusões causais.

3.10 Síntese da Metodologia

A metodologia adotada neste trabalho estabeleceu um processo experimental padronizado e reprodutível para avaliar diferentes abordagens de previsão de renda.

De forma geral, o processo envolveu:

- Utilização de microdados da PNAD Contínua;
- Definição da renda mensal do trabalho principal deflacionada como variável alvo;
- Limpeza e preparação dos dados;
- Engenharia de atributos socioeconômicos;
- Criação de variáveis de interação;
- Divisão dos dados em treino, validação e teste;
- Aplicação de transformação logarítmica na variável alvo;
- Correção de viés por smearing correction;
- Treinamento e avaliação de modelos lineares, modelos de Machine Learning e modelo híbrido;
- Comparação dos modelos por métricas no espaço logarítmico e na escala original;
- Discussão sobre interpretabilidade, explicabilidade e limitações das previsões.

Essa metodologia permite uma comparação justa entre diferentes abordagens de modelagem, sustentando a análise dos resultados apresentada no capítulo seguinte. Além disso, reforça o caráter de Sistemas de Informação do trabalho, ao integrar engenharia de dados, modelagem preditiva, avaliação experimental e posterior disponibilização do modelo em uma aplicação web.

4 DESENVOLVIMENTO DO SISTEMA

Este capítulo descreve a arquitetura e a implementação do sistema preditivo desenvolvido neste trabalho, contemplando a integração entre o modelo de Machine Learning, o backend responsável pelo processamento das requisições e a interface gráfica utilizada para interação com o usuário final.

O sistema foi projetado considerando princípios de modularidade, separação de responsabilidades, reprodutibilidade experimental e facilidade de manutenção. Como o trabalho não se limita apenas ao treinamento de modelos, mas também envolve a construção de uma aplicação funcional, a arquitetura foi organizada de forma que cada parte do sistema tenha uma responsabilidade bem definida.

Além disso, a implementação buscou manter consistência entre o ambiente de treinamento e o ambiente de inferência. Isso é importante porque, em sistemas preditivos, pequenas diferenças na ordem das variáveis, no tratamento de dados categóricos ou na aplicação das transformações podem gerar previsões incorretas. Dessa forma, a arquitetura foi construída para preservar os mesmos critérios utilizados durante a etapa de modelagem.

4.1 Visão Geral da Arquitetura

O sistema foi estruturado em três camadas principais:

- Camada de Modelagem, composta pelo ML Pipeline;
- Camada de Serviço, composta pelo backend em Python;
- Camada de Apresentação, composta pelo frontend em React.

A camada de modelagem é responsável pelo processamento dos dados, treinamento dos modelos, avaliação dos resultados e persistência dos arquivos necessários para inferência. A camada de serviço atua como intermediária entre o modelo treinado e a aplicação web, recebendo os dados enviados pelo usuário, validando as informações e retornando a previsão. A camada de apresentação permite que o usuário interaja com o sistema por meio de uma interface gráfica.

A comunicação entre frontend e backend ocorre por meio de requisições HTTP, utilizando uma API REST. Essa escolha permite desacoplar a interface da lógica de predição, tornando o sistema mais flexível e facilitando futuras alterações.

A arquitetura adotada permite:

- Atualização independente do modelo;
- Separação entre lógica de negócio, modelagem e interface;
- Facilidade de manutenção;
- Possibilidade de substituição ou atualização dos algoritmos;
- Organização modular do código;
- Escalabilidade futura.

Essa divisão em camadas também reforça o caráter de Sistemas de Informação do projeto, pois transforma a modelagem preditiva em uma solução acessível por meio de uma aplicação web funcional.

4.2 Pipeline de Modelagem

A camada de modelagem foi implementada em Python, utilizando bibliotecas especializadas para análise de dados, treinamento de modelos e persistência dos artefatos gerados.

As principais bibliotecas utilizadas foram:

- pandas;
- numpy;
- scikit-learn;
- catboost;
- joblib.

O pipeline foi organizado em módulos, com o objetivo de separar as diferentes etapas do processo experimental. Essa organização facilita a manutenção do código e permite repetir os experimentos de forma controlada.

O pipeline contempla as seguintes etapas:

- Extração e processamento dos dados;
- Limpeza e padronização das variáveis;
- Engenharia de atributos;
- Geração dos conjuntos de treino, validação e teste;
- Treinamento dos modelos;
- Avaliação padronizada;
- Cálculo de métricas;
- Persistência dos modelos treinados;
- Armazenamento dos metadados necessários para inferência.

Os modelos treinados são salvos no diretório `models/`, juntamente com metadados importantes para o funcionamento correto do backend. Entre esses metadados estão:

- Lista de variáveis utilizadas no treinamento;
- Lista de variáveis categóricas;
- Ordem esperada das colunas;
- Fator de smearing;
- Métricas de validação;
- Informações sobre a versão do modelo.

Essa estrutura garante que o backend consiga reproduzir corretamente as previsões realizadas durante o treinamento. Dessa forma, evita-se que o modelo receba variáveis em ordem incorreta, com tipos inadequados ou sem as transformações necessárias.

Além do aspecto técnico, o pipeline também contribui para a reprodutibilidade do trabalho, pois permite que os experimentos sejam refeitos a partir de uma estrutura padronizada. Isso é importante para validar os resultados apresentados e para possibilitar futuras melhorias no projeto.

4.3 Backend em Python

O backend foi desenvolvido utilizando FastAPI, um framework moderno para construção de APIs em Python. A escolha do FastAPI se justifica por sua

simplicidade, bom desempenho, suporte a validação de dados e facilidade de integração com aplicações web.

O backend possui como principal responsabilidade disponibilizar o modelo treinado para uso pela interface web. Para isso, ele recebe os dados informados pelo usuário, organiza essas informações no formato esperado pelo modelo e executa a predição.

As principais responsabilidades do backend são:

- Receber requisições HTTP contendo os atributos do usuário;
- Validar os dados recebidos;
- Converter os dados para o formato adequado;
- Organizar as variáveis na ordem esperada pelo modelo;
- Tratar variáveis categóricas;
- Executar a predição;
- Aplicar a transformação inversa do logaritmo;
- Aplicar o fator de smearing;
- Retornar o valor estimado de renda;
- Retornar informações auxiliares, como métricas ou indicador aproximado de incerteza.

O backend carrega o modelo previamente treinado durante sua inicialização. Essa decisão evita que o modelo seja recarregado a cada requisição, melhorando o desempenho da aplicação e reduzindo o tempo de resposta para o usuário.

O fluxo interno da predição ocorre da seguinte forma:

1. Recebimento dos dados via endpoint `/predict`;
2. Validação dos campos recebidos;
3. Conversão dos dados para um DataFrame;
4. Reorganização das colunas conforme a ordem esperada pelo modelo;
5. Conversão das variáveis categóricas para string, quando necessário;
6. Execução da predição em escala logarítmica;
7. Aplicação da transformação inversa do logaritmo;
8. Aplicação do smearing correction;
9. Geração do resultado em escala monetária;
10. Retorno da resposta em formato JSON.

Essa abordagem garante maior consistência entre o ambiente de treinamento e o ambiente de produção. Também reduz o risco de erros comuns em sistemas de Machine Learning, como divergência entre as variáveis usadas no treinamento e as variáveis recebidas durante a inferência.

É importante destacar que o backend não realiza novo treinamento a cada requisição. Ele apenas utiliza um modelo previamente treinado e validado. Assim, o sistema separa claramente a etapa experimental de modelagem da etapa operacional de predição.

4.4 Interface Web em React

A interface gráfica foi desenvolvida utilizando React, biblioteca JavaScript amplamente utilizada para construção de aplicações web modernas. A escolha do React permitiu a criação de uma interface dinâmica, organizada em componentes e de fácil manutenção.

A interface tem como objetivo permitir que usuários não técnicos consigam utilizar o modelo preditivo sem necessidade de executar scripts ou interagir diretamente com o código. Dessa forma, o sistema torna a previsão de renda mais acessível e compreensível.

As principais funcionalidades da interface são:

- Formulário estruturado para entrada de dados socioeconômicos;
- Validação básica de campos obrigatórios;
- Organização visual das informações solicitadas;
- Envio dos dados ao backend por meio de requisição HTTP;
- Exibição do valor estimado de renda;
- Apresentação de indicador aproximado de erro ou incerteza;
- Exibição clara do resultado para o usuário.

A interface foi projetada com foco em usabilidade, permitindo que o usuário insira informações como:

- Escolaridade;
- Idade;

- Região;
- Horas trabalhadas;
- Situação ocupacional;
- Características do trabalho;
- Dados relacionados à formalização e ocupação.

Após o preenchimento do formulário, os dados são enviados ao backend, que processa a requisição e retorna a estimativa de renda. O resultado é apresentado de forma clara, destacando:

- Valor estimado da renda mensal;
- Informação de que o resultado é uma estimativa;
- Indicador de incerteza associado ao modelo;
- Possibilidade de interpretação cautelosa do valor previsto.

A apresentação do resultado considera a natureza probabilística do modelo. Portanto, o sistema não trata a previsão como um valor exato, mas como uma estimativa baseada em padrões observados nos dados da PNAD Contínua.

4.5 Fluxo Completo da Requisição

O fluxo operacional do sistema ocorre a partir da interação do usuário com a interface web. Esse fluxo foi definido para manter separação clara entre apresentação, processamento e modelagem.

O processo completo ocorre da seguinte forma:

1. O usuário preenche o formulário na interface React;
2. O frontend valida os campos básicos;
3. O frontend envia uma requisição POST para o backend;
4. O backend recebe os dados e realiza a validação;
5. O backend organiza as variáveis no formato esperado pelo modelo;
6. O modelo de Machine Learning realiza a predição em escala logarítmica;
7. O backend aplica a transformação inversa do logaritmo;
8. O backend aplica o fator de smearing;
9. O resultado é convertido para escala monetária;
10. O backend retorna a resposta em formato JSON;

11.0 frontend apresenta o valor estimado ao usuário.

Esse fluxo garante separação clara entre:

- Interface;
- Validação;
- Processamento;
- Modelagem;
- Retorno da resposta.

Essa separação facilita futuras manutenções. Por exemplo, caso o modelo seja atualizado, o frontend não precisa ser refeito, desde que o formato da API seja preservado. Da mesma forma, alterações visuais na interface podem ser realizadas sem modificar a lógica de predição.

4.6 Estrutura de Diretórios

A organização do projeto foi estruturada de forma modular, separando os componentes de modelagem, backend e frontend. Essa separação facilita a manutenção, o versionamento e a evolução futura do sistema.

A estrutura geral do projeto foi organizada da seguinte forma:

```
ml_pipeline/
```

```
    src/
```

```
        data/
```

```
        models/
```

```
        utils/
```

```
        debug/
```

```
models/
```

```
data/
```

backend/

frontend/

O diretório `ml_pipeline/` concentra os scripts e arquivos relacionados ao processo de modelagem. Dentro dele, estão os módulos responsáveis por leitura dos dados, transformação das variáveis, treinamento, avaliação e salvamento dos modelos.

O diretório `models/` armazena os modelos treinados e os metadados necessários para inferência. O diretório `data/` concentra os arquivos de dados utilizados no pipeline, respeitando a organização das versões utilizadas durante o desenvolvimento.

O diretório `backend/` contém a API desenvolvida em FastAPI, responsável por carregar o modelo e responder às requisições de predição. Já o diretório `frontend/` contém a aplicação React, responsável pela interação com o usuário.

Essa organização facilita:

- Manutenção do código;
- Versionamento do projeto;
- Testes isolados;
- Separação de responsabilidades;
- Evolução futura do sistema;
- Substituição de componentes sem comprometer toda a aplicação.

4.7 Controle de Versão e Reprodutibilidade

O projeto foi versionado utilizando Git, permitindo o controle das alterações realizadas ao longo do desenvolvimento. O uso de versionamento é importante porque o projeto envolve diferentes etapas, como processamento de dados, treinamento de modelos, ajustes no backend e desenvolvimento da interface.

O versionamento permite:

- Controle de alterações no código;
- Histórico de experimentos;
- Organização por versões do modelo;
- Recuperação de versões anteriores;
- Melhor acompanhamento da evolução do sistema.

Durante o desenvolvimento, diferentes versões do modelo foram geradas e avaliadas. A consolidação do dataset na versão v3 e a padronização do protocolo de avaliação foram decisões importantes para garantir reprodutibilidade experimental.

A reprodutibilidade também foi considerada por meio da persistência dos modelos treinados e dos metadados associados. Dessa forma, o sistema não depende apenas do código de treinamento, mas também dos arquivos necessários para que a inferência ocorra corretamente.

Essa preocupação é relevante porque, em projetos de Machine Learning, não basta apenas treinar um modelo com bom desempenho. É necessário garantir que ele possa ser carregado, utilizado e avaliado novamente de forma consistente.

4.8 Deploy e Execução Local

O sistema foi preparado para execução local, permitindo testes integrados entre backend e frontend antes de uma eventual implantação em ambiente de produção.

A execução local ocorre por meio dos seguintes passos:

1. Inicialização do backend com servidor FastAPI;
2. Carregamento do modelo treinado e seus metadados;
3. Inicialização do frontend React;
4. Comunicação entre frontend e backend por meio da porta local configurada;
5. Envio de requisições de teste para o endpoint de predição;
6. Exibição dos resultados na interface web.

Essa configuração permite verificar se todas as partes do sistema estão funcionando corretamente de forma integrada. Assim, é possível testar o preenchimento do formulário, o envio dos dados, o processamento da requisição, a execução da predição e a apresentação do resultado ao usuário.

Embora o sistema tenha sido executado localmente durante o desenvolvimento, sua arquitetura permite futura implantação em ambiente de produção. Entre as possibilidades de evolução estão:

- Containerização com Docker;
- Deploy do backend em serviço de nuvem;
- Deploy do frontend em plataforma web;
- Criação de API pública;
- Automatização de atualização do modelo.

Essas possibilidades foram consideradas como trabalhos futuros, pois o foco principal deste trabalho foi a construção de um sistema funcional, reprodutível e validado em ambiente local.

5 RESULTADOS E ANÁLISE

Este capítulo apresenta os resultados obtidos nos experimentos realizados, comparando modelos lineares, modelos baseados em árvores de decisão e uma abordagem híbrida. A análise considera métricas de desempenho, estabilidade dos modelos, interpretação dos resultados e limitações metodológicas.

5.1 Protocolo Experimental

Para garantir consistência metodológica e reprodutibilidade, foi adotado um protocolo fixo de avaliação. O dataset utilizado foi a versão consolidada v3, com divisão previamente definida entre treino, validação e teste. A variável alvo foi `renda_mensal_ocupacao_principal_deflacionado`, representando a renda mensal do trabalho principal.

Durante o treinamento, a variável alvo foi transformada para escala logarítmica, com o objetivo de reduzir a assimetria da distribuição de renda.

Após a predição, os valores foram reconvertidos para a escala original com aplicação do fator de smearing, quando necessário.

A avaliação final foi realizada exclusivamente sobre o conjunto de teste, não utilizado no treinamento. Além disso, foi aplicada validação cruzada 5-fold no conjunto de treino, permitindo verificar a estabilidade dos modelos.

As métricas utilizadas foram:

- R^2 , coeficiente de determinação;
- RMSE, raiz do erro quadrático médio;
- MAE, erro absoluto médio.

As métricas foram calculadas tanto no espaço logarítmico quanto na escala original da renda. Essa escolha permite avaliar o desempenho do modelo na escala de aprendizado e também o impacto prático da previsão em valores monetários.

5.2 Resultados Comparativos

Após a consolidação do dataset e a padronização do protocolo experimental, foram obtidos os seguintes resultados principais:

Modelo Mincer – Regressão Linear Estrutural

- R^2 log: 0.4415;
- R^2 original: 0.3513;
- RMSE original: 1027,06;
- MAE original: 592,63.

CatBoost Global V5

- R^2 log: 0.5913;
- R^2 original: 0.4635;
- RMSE original: 934,09;
- MAE original: 482,82.

Na validação cruzada 5-fold, o CatBoost obteve:

- Média R^2 log: 0.5816;
- Desvio padrão: 0.0047.

Modelo Híbrido – Mincer + CatBoost Residual

- R^2 log: 0.5889;
- R^2 original: 0.4906;
- RMSE original: 910,17;
- MAE original: 528,32.

Na validação cruzada 5-fold, o modelo híbrido obteve:

- Média R^2 log: 0.5807;
- Desvio padrão: 0.0051.

De forma geral, os modelos baseados em Machine Learning apresentaram desempenho superior ao modelo linear estrutural. O CatBoost demonstrou melhor equilíbrio entre desempenho, estabilidade e simplicidade de uso, enquanto o modelo híbrido apresentou resultado metodologicamente relevante, mas sem ganho expressivo em relação ao CatBoost puro.

5.3 Análise Técnica dos Resultados

5.3.1 Ganho em Relação ao Modelo Estrutural

O modelo baseado na equação de Mincer apresentou desempenho inferior aos modelos de aprendizado de máquina. A diferença foi de aproximadamente 15 pontos percentuais em R^2 na escala logarítmica e cerca de 11 pontos percentuais na escala original.

Esse resultado indica que modelos lineares apresentam limitações para capturar padrões mais complexos presentes nos dados, como:

- Interações não lineares entre variáveis;
- Efeitos regionais;
- Relações não monotônicas entre escolaridade, idade e renda;
- Diferenças associadas à ocupação e à formalização do trabalho.

Assim, os resultados reforçam a utilidade de modelos de Machine Learning em problemas preditivos envolvendo renda, especialmente quando o objetivo principal é melhorar a capacidade de previsão.

5.3.2 CatBoost e Modelo Híbrido

A comparação entre o CatBoost puro e o modelo híbrido mostrou desempenho bastante próximo na validação cruzada. A diferença média entre os modelos foi de apenas 0.0009 em R^2 log, com desvios padrão semelhantes.

Isso sugere que o modelo híbrido não apresentou ganho estatisticamente relevante em capacidade preditiva global. Apesar disso, ele possui importância metodológica, pois combina uma estrutura econométrica interpretável com um modelo de Machine Learning aplicado aos resíduos.

A análise das variáveis indicou que o modelo residual capturou padrões associados a fatores como:

- Horas trabalhadas;
- Posição ocupacional;
- Setor de atividade;
- Unidade federativa;
- Interações entre idade e escolaridade.

Dessa forma, o modelo híbrido cumpre o papel de capturar efeitos que não foram explicados pela regressão linear inicial. No entanto, do ponto de vista prático, o CatBoost puro apresentou desempenho semelhante com menor complexidade estrutural.

5.3.3 Estabilidade Estatística

A validação cruzada demonstrou boa estabilidade nos modelos avaliados. O CatBoost apresentou média de R^2 log igual a 0.5816, com desvio padrão de 0.0047. O modelo híbrido apresentou média de 0.5807, com desvio padrão de 0.0051.

Os baixos desvios indicam que os modelos possuem comportamento consistente entre diferentes divisões dos dados de treino. Isso reduz indícios de sobreajuste e sugere boa capacidade de generalização.

5.3.4 Intervalo Preditivo

Foi estimado um intervalo preditivo aproximado de 95% com base no desvio padrão dos resíduos logarítmicos. O CatBoost apresentou sigma aproximado de 0.5825, enquanto o modelo híbrido apresentou sigma aproximado de 0.5972.

A existência de intervalos relativamente amplos é esperada nesse tipo de problema, pois a renda possui alta variabilidade e depende de fatores que não estão totalmente representados na base de dados. Entre esses fatores estão características individuais, condições específicas do mercado de trabalho, oportunidades locais e aspectos subjetivos.

Portanto, a previsão gerada pelo sistema deve ser entendida como uma estimativa probabilística, e não como um valor exato ou determinístico.

5.3.5 Interpretação do R^2

O R^2 entre aproximadamente 0.46 e 0.49 na escala original indica que os modelos conseguiram explicar cerca de metade da variabilidade da renda com as variáveis disponíveis.

Esse resultado é relevante considerando a complexidade do fenômeno analisado. A renda é influenciada por fatores observáveis, como escolaridade, idade, ocupação e região, mas também por fatores não observáveis, como habilidade individual, experiência real acumulada, reputação, networking e condições específicas da empresa ou localidade.

Assim, o desempenho obtido é consistente com a dificuldade do problema e com aplicações empíricas de previsão em dados socioeconômicos.

5.4 Discussão Metodológica

Os resultados obtidos reforçam a ideia de que modelos de Machine Learning tendem a apresentar melhor desempenho do que modelos lineares quando o objetivo principal é previsão. Esse comportamento está alinhado com a discussão de Mullainathan e Spiess (2017), segundo a qual modelos de aprendizado de máquina são especialmente úteis em tarefas preditivas.

A abordagem híbrida também representa uma contribuição metodológica relevante, pois combina:

- Estrutura interpretável baseada na equação de Mincer;
- Modelagem não linear por meio do CatBoost;
- Correção de viés na retransformação logarítmica por smearing.

Entretanto, sob o critério puramente preditivo, o CatBoost puro apresentou desempenho equivalente com menor complexidade. Dessa forma, a escolha do modelo final deve considerar não apenas as métricas de erro, mas também simplicidade, estabilidade, interpretabilidade e facilidade de integração ao sistema.

Também é importante diferenciar interpretabilidade e explicabilidade. O modelo Mincer é mais interpretável, pois seus coeficientes podem ser analisados diretamente. Já o CatBoost possui menor interpretabilidade estrutural, mas pode ser explicado por técnicas auxiliares, como importância de variáveis e SHAP. Essa distinção é importante para evitar que o modelo seja tratado apenas como uma “caixa-preta”.

5.5 Limitações

As principais limitações do trabalho estão relacionadas à natureza dos dados e ao escopo do projeto. O modelo depende exclusivamente das variáveis disponíveis na PNAD Contínua, não incorporando fatores subjetivos ou qualitativos, como habilidade individual, networking, reputação profissional e qualidade da formação.

Além disso, a renda apresenta alta variabilidade natural, e o modelo não realiza análise temporal longitudinal. Também não foi implementada modelagem explícita de heterocedasticidade, e os intervalos preditivos utilizados são aproximados.

Outra limitação é que os modelos baseados em árvores, apesar do bom desempenho, possuem menor interpretabilidade direta quando comparados a regressões lineares. Por isso, análises futuras podem aprofundar o uso de técnicas de explicabilidade, como SHAP, para compreender melhor a contribuição de cada variável nas previsões.

5.6 Implicações Práticas

O sistema desenvolvido pode ser utilizado como ferramenta exploratória para estimativa de renda mensal com base em características socioeconômicas. Entre suas possíveis aplicações estão:

- Simulações de renda esperada;
- Apoio exploratório a estudos sobre mercado de trabalho;
- Ferramenta educacional;
- Análise comparativa entre perfis socioeconômicos;
- Base para estudos futuros em modelagem preditiva.

A existência de uma interface web amplia a aplicabilidade do sistema, permitindo que usuários não técnicos realizem simulações sem necessidade de interagir diretamente com o código ou com o modelo.

5.7 Síntese dos Resultados

Os experimentos realizados indicam que os modelos de Machine Learning superaram a regressão linear tradicional na tarefa de previsão de renda. O CatBoost apresentou bom equilíbrio entre desempenho, estabilidade e simplicidade, enquanto o modelo híbrido se mostrou metodologicamente interessante, mas não superior em desempenho global.

Os resultados também mostram que o modelo consegue explicar aproximadamente metade da variabilidade da renda, o que é consistente com a complexidade do fenômeno analisado e com as limitações dos dados disponíveis.

Dessa forma, conclui-se que o objetivo do trabalho foi alcançado: desenvolver um sistema preditivo funcional, estatisticamente estável e tecnicamente consistente para estimativa de renda mensal com base em dados públicos da PNAD Contínua.

6 CONCLUSÃO E TRABALHOS FUTUROS

6.1 Conclusão

O presente trabalho teve como objetivo desenvolver um sistema preditivo capaz de estimar a renda mensal do trabalho principal com base em dados públicos da PNAD Contínua, utilizando técnicas de aprendizado de máquina integradas a uma aplicação web.

A motivação central foi investigar se modelos modernos de Machine Learning seriam capazes de apresentar melhor desempenho do que abordagens econométricas tradicionais na tarefa de previsão de renda. Além disso, buscou-se construir uma solução organizada, reproduzível e aplicável ao contexto de Sistemas de Informação.

Os resultados obtidos demonstraram que os modelos lineares estruturais, como a regressão baseada na equação de Mincer, apresentam desempenho mais limitado na previsão da renda. Por outro lado, modelos baseados em árvores, especialmente o CatBoost, apresentaram desempenho superior, indicando maior capacidade de capturar relações não lineares e interações entre variáveis socioeconômicas.

A abordagem híbrida, composta pela combinação entre Mincer e CatBoost aplicado aos resíduos, mostrou-se metodologicamente relevante por unir uma estrutura interpretável com a capacidade de modelagem não linear do aprendizado de máquina. No entanto, em termos puramente preditivos, o CatBoost puro apresentou desempenho semelhante com menor complexidade.

O melhor modelo alcançou aproximadamente R^2 de 0,49 na escala original, além de redução significativa no RMSE em comparação à regressão linear tradicional. Esse resultado indica que técnicas modernas de aprendizado supervisionado são adequadas para problemas de previsão de renda, especialmente quando o objetivo principal é aumentar a capacidade preditiva.

Também foi considerada a diferença entre interpretabilidade e explicabilidade dos modelos. Enquanto os modelos lineares apresentam maior interpretabilidade estrutural, modelos como o CatBoost exigem técnicas auxiliares para explicar melhor o comportamento das previsões. Assim, os resultados devem ser interpretados como estimativas preditivas, e não como relações causais definitivas.

Além da etapa de modelagem, o trabalho resultou na construção de:

- Pipeline estruturado de treinamento;
- Protocolo experimental reprodutível;
- Backend em Python com FastAPI;
- Interface web em React;
- Integração completa entre modelo, backend e frontend.

Sob a perspectiva de Sistemas de Informação, o trabalho não se limita à construção de modelos estatísticos, mas entrega um sistema funcional completo, contemplando arquitetura, integração, versionamento, execução local e disponibilização prática das previsões.

Dessa forma, considera-se que os objetivos propostos foram atingidos, com a entrega de uma solução tecnicamente consistente, reprodutível e academicamente fundamentada para previsão de renda mensal com base em dados públicos.

6.2 Contribuições do Trabalho

As principais contribuições deste trabalho podem ser organizadas em três dimensões: técnica, metodológica e sistêmica.

Contribuição Técnica

- Implementação de múltiplos modelos comparativos;
- Consolidação de um dataset padronizado;
- Criação de um protocolo fixo de avaliação;
- Aplicação de transformação logarítmica na variável alvo;
- Implementação da correção de viés por Smearing Estimator;
- Estrutura modular e reproduzível para treinamento e avaliação.

Contribuição Metodológica

- Comparação estruturada entre econometria clássica e Machine Learning;
- Aplicação prática de modelo híbrido;
- Avaliação dos modelos em escala logarítmica e escala original;
- Discussão sobre desempenho, interpretabilidade e explicabilidade;
- Análise crítica das limitações das previsões geradas.

Contribuição Sistêmica

- Desenvolvimento de uma aplicação web funcional;
- Integração entre modelo, backend e frontend;
- Disponibilização do modelo por meio de API;
- Possibilidade de uso da ferramenta por usuários não técnicos;
- Organização do sistema com separação clara de responsabilidades.

6.3 Limitações

Apesar dos resultados obtidos, o trabalho apresenta algumas limitações. A primeira delas é a dependência exclusiva das variáveis disponíveis na PNAD Contínua. Embora essa base seja ampla e relevante, ela não contém todos os fatores que podem influenciar a renda individual.

Entre os fatores não observados estão habilidades pessoais, qualidade da formação, networking, reputação profissional, características específicas da empresa, oportunidades locais e condições momentâneas do mercado de trabalho. Esses elementos podem afetar a renda, mas não foram capturados diretamente pelo modelo.

Além disso, não foram incorporadas variáveis macroeconômicas externas, como inflação regional, taxa de desemprego local ou indicadores setoriais. O modelo também possui caráter estático, ou seja, não realiza atualização temporal automática com novos dados.

Outra limitação importante é que não foi implementada uma análise completa de fairness ou viés algorítmico. Portanto, não foram avaliados de forma aprofundada possíveis comportamentos distintos do modelo em grupos definidos por sexo, raça, região ou outras características sensíveis.

Também é importante destacar que modelos baseados em árvores, como o CatBoost, possuem menor interpretabilidade direta quando comparados a modelos lineares. Embora seja possível utilizar técnicas de explicabilidade, como SHAP, essa análise pode ser aprofundada em trabalhos futuros.

Essas limitações são compatíveis com o escopo de um trabalho de graduação e não invalidam os resultados, mas indicam pontos importantes para evolução da pesquisa.

6.4 Trabalhos Futuros

O trabalho abre diversas possibilidades de evolução. Entre as principais estão:

1. Atualização Temporal do Modelo

Implementar um processo de re-treinamento periódico com novos microdados da PNAD Contínua, permitindo que o modelo acompanhe mudanças no mercado de trabalho e na distribuição de renda ao longo do tempo.

2. Explicabilidade com SHAP

Aprofundar a explicação dos modelos utilizando SHAP values, permitindo analisar com maior detalhe a contribuição de cada variável nas previsões. Essa melhoria ajudaria a compreender melhor o comportamento do CatBoost e a reduzir sua característica de “caixa-preta”.

3. Fairness e Análise de Viés

Avaliar se o modelo apresenta diferenças sistemáticas de erro ou comportamento preditivo entre grupos, como sexo, raça, região, faixa etária ou nível de escolaridade. Essa análise seria importante para aumentar a responsabilidade e a transparência do sistema.

4. Intervalos Preditivos Mais Robustos

Implementar modelos capazes de retornar não apenas um ponto estimado de renda, mas também uma faixa de probabilidade mais bem calibrada. Isso permitiria representar melhor a incerteza natural do problema.

5. Modelos Baseados em Deep Learning

Explorar redes neurais profundas ou outras arquiteturas de aprendizado para verificar se há ganho de desempenho em relação aos modelos baseados em árvores.

6. Deploy em Ambiente de Produção

Realizar a implantação do sistema em ambiente de produção, com hospedagem em nuvem, containerização com Docker e disponibilização pública da API e da interface web.

7. Expansão para Outras Variáveis

Expandir o sistema para prever outras variáveis relacionadas ao mercado de trabalho, como:

- Probabilidade de informalidade;
 - Faixa salarial;
 - Mobilidade ocupacional;
 - Probabilidade de empregabilidade;
 - Comparação entre perfis profissionais.
-

6.5 Considerações Finais

Este trabalho demonstrou que a integração entre técnicas de Machine Learning e arquitetura de software permite a construção de sistemas preditivos aplicáveis ao contexto socioeconômico brasileiro.

A consolidação metodológica realizada ao longo do projeto garante que os resultados não sejam fruto de experimentação isolada, mas de um processo estruturado, versionado e reproduzível. A comparação entre modelos lineares, modelos de Machine Learning e abordagem híbrida permitiu avaliar diferentes perspectivas sobre o problema de previsão de renda.

Sob a ótica de Sistemas de Informação, o projeto evidencia a importância da combinação entre:

- Engenharia de dados;
- Modelagem preditiva;
- Avaliação experimental;
- Arquitetura de software;
- Interface com o usuário.

Conclui-se, portanto, que o sistema desenvolvido representa uma solução tecnicamente consistente e academicamente fundamentada para previsão de renda mensal com base em dados públicos da PNAD Contínua. O trabalho também estabelece uma base sólida para futuras melhorias, especialmente nas áreas de explicabilidade, análise de viés, atualização temporal e implantação em produção.